

Lista de Exercícios 08

(prazo final para entrega: 06/05/2019 - segunda)

- 1) Implemente as seguintes métricas de classificação:
 - a) As métricas devem funcionar para classificação binária ou mesmo para múltiplas classes. Dica: você pode usar a função [confusion_matrix do Scikit Learn](#) para construir uma matriz de confusão e facilitar os seus cálculos. As métricas devem retornar a média ponderada com pesos baseados no suporte.
 - i) accuracy
 - ii) precision
 - iii) recall
 - iv) f1_measure
- 2) Divida de forma estratificada o [Dataset Iris](#) em apenas 10% para treino e 90% para teste. Essa divisão não é usual, mas vamos usar para tornar o problema mais desafiador.
 - Faça a standardização dos dados.
- 3) Crie um modelo preditivo de classificação multi-classe usando [Logistic Regression](#).
 - **Dica:** você pode usar os parâmetros: multi_class='auto', solver='lbfgs'
- 4) Avalie usando suas implementações das métricas: accuracy, precision, recall e f1_measure.
- 5) Calcule a métrica [log_loss usando a implementação do sklearn](#).
 - a) Observe exemplos sobre Métricas de Classificação no [github da disciplina](#). Lá tem exemplos completos.
 - b) Note que y_pred em log_loss, nós chamamos de y_score, que é a probabilidade de ocorrência de cada classe para aquela linha do dataset
- 6) Desenhe a curva ROC para a classe Iris-virginica usando a [implementação do sklearn](#).
 - a) use a função roc_auc_score(y_true, y_score).
 - i) preste atenção que y_score é diferente de y_pred.
 - **Dicas:** Observe exemplos sobre Métricas de Classificação no [github da disciplina](#). Lá tem exemplos completos.
- 7) Calcule a métrica AUC (Area Under Curve) para a classe Iris-virginica usando a [implementação do sklearn](#).
 - **Dica:** Observe exemplos sobre Métricas de Classificação no [github da disciplina](#). Lá tem exemplos completos.

